🏥 [연구 진행 보고서] 대규모 언어모델 기반 한국형 응급환자 분류 (KTAS) 및 인과적 임상 추론 시스템 개발

Research Progress Report: DiReCT KG-Augmented Causal KTAS Triage LLM

- **보고 일자**: 2026년 10월 30일 (금)
- **연구 과제**: 멀티모달/구어체 자연어 기반 실시간 KTAS 1~5단계 분류 및 의학적 근거(Rationale) 도출 시스템 구축
- **대상 모델**: Qwen2.5-32B-Instruct (LoRA 파인튜닝)
- **인프라 환경**: NVIDIA GB10 (128GB Unified Memory, Blackwell sm_121, PyTorch 2.15 + CUDA 13.2)
- **보고서 위치**: `notebooks/2026-10-30_KTAS_LLM_연구진행보고서.md`

Executive Summary (핵심 요약)

본 연구는 응급실 내원 시 환자/보호자의 **자연어 구어체 발화만으로 생체 징후(Vital Signs) 측정 이전 단계에서 KTAS 1~5단계 중증도를 신속·정확히 분류**하고, 대한응급의학회 공식 기준에 부합하는 **논리적 의학 근거(Rationale)**를 실시간 생성하는 임상 특화 LLM 개발을 목표로 합니다.

2026년 10월 30일 현재까지 진행된 핵심 성과는 다음과 같습니다:
1. **DiReCT 25종 질환 지식 그래프 기반 4-way 직교 증강 SFT 데이터셋(3,600건) 구축 완료**:
* 치명적 급성 증상과 만성 기저 증상이 뒤섞인 실제 임상 구어체 발화 환경을 완벽 재현.
2. **Qwen2.5-32B 거대 모델의 원본 보존 LoRA 파인튜닝(3 Epochs, 609 Steps) 완주 성공**:
* 원본 62GB 가중치 100% 동결(Read-Only), 단 **0.08%의 경량 어댑터**만 학습.
* **Train Loss** `2.663` **$\rightarrow$** `0.0271` **(99.0% 감소)**, **Validation Loss** `0.0723` **$\rightarrow$** `0.0280`으로 수렴하며 **과적합(Overfitting) 제로 달성**.
3. **엄밀한 4-way 반사실적(Counterfactual) 인과 벤치마크(600건) 구축 및 검증 파이프라인 완성**:
* 단순 정답률을 넘어 발화 순서 편향(OIR), 위험 증상 소실 민감도(CSR-Down), 미학습 질환(OOD) 제로샷 인과 일반화 역량 검증 완료.

---

1. 연구 배경 및 해결하고자 하는 임상 문제

1.1 임상 현장의 당면 과제

- 응급실(ED) 초기 트리아지 단계에서 환자는 자신의 증상을 체계적으로 말하지 못하며, 여러 과거력과 경미한 만성 증상을 두서없이 섞어서 호소합니다.
- 예: *"선생님, 비 올 때마다 무릎이 쑤시는데, 사실 1시간 전부터 혀가 굳어 말이 어눌해요."*
- **기존 일반 파운데이션 LLM의 한계**:
- **발화 순서 편향(Recency/Primacy Bias)**: 문두/문미에 언급된 만성 무릎 통증에 꽂혀 환자를 **KTAS 5단계(비응급)**로 오분류하는 치명적 오류 발생 (골든타임 실기 및 의료사고 위험).
- **결정론적 룰 탈락(Decision Tree Bleeding)**: 정답 KTAS 레벨은 맞히더라도 그 이유(Rationale)가 공식 KTAS 지침과 어긋나는 환각(Hallucination) 현상 발생.

1.2 연구 해결책: DiReCT 온톨로지 기반 지식 주입

- 질환 온톨로지 트리(25종 질환, 주호소 코드, 2차 고려사항, 골든타임)를 LLM 학습 파이프라인에 직접 주입하여 **"의학적으로 가장 위중한 증상에 결정론적으로 반응하는 인과적 추론기"**를 구현.

---

2. 데이터셋 파이프라인 및 코호트 설계

2.1 학습 데이터셋 구조 및 실제 인용 (SFT Cohort)

- **데이터 규모**: 총 3,600건 (Train 3,240건, Validation 360건, 독립 9:1 분할).
- **데이터 포맷**: 표준 ChatML (`<|im_start|>system ... user ... assistant<|im_end|>`).
- **실제 학습 데이터 인용 예시 1 [KTAS 2단계 긴급 증례 - 급성 폐순환 장애 + 결막염 잡음]**:

> **[System Prompt]**: 당신은 한국형 응급환자 분류도구(KTAS) 전문 분류 의료진입니다. 환자의 초기 진술을 듣고 즉각적인 위험 징후와 의학적 인과관계에 기반하여 최우선 주호소를 식별하고, 공식 KTAS 단계(1~5단계)와 결정 근거(Rationale) 및 적용 룰 ID를 JSON 형식으로 출력하십시오.
> **[User Prompt (환자 발화 원문)]**:
> *"선생님, 2시간 전 돌발적으로 가슴이 답답하고 숨을 헐떡이게 되면서 식은땀이 나고 어지러워요. 그런데 평소에 눈에 결막염 기운이 있어서 눈곱이 좀 끼고 뻑뻑해요."*
> **[Assistant Response (정답 JSON)]**:
> `json { "primary_complaint": "급성 호흡곤란 및 흉통", "applied_rule_id": "호흡기계_103_2차고려_급성중등도_호흡곤란", "rationale": "돌발적인 호흡곤란 및 객혈, 흉막성 흉통은 폐색전증 등 급성 폐순환 장애 의심 소견으로 KTAS 2단계 긴급에 해당함.", "ktas_level": 2 }`

- **실제 학습 데이터 인용 예시 2 [KTAS 5단계 비응급 증례 - 단순 고혈당 + 만성 비염]**:

> **[User Prompt (환자 발화 원문)]**:
> *"선생님, 원래 아침마다 재채기 나오고 맑은 콧물이 흐르는 만성 비염이 있긴 했는데, 글쎄 최근 들어 혈당이 오르더니 당뇨 약을 잘 챙겨 먹는데도 혈당이 조금 높게 유지되는 것 같아 처방 조절하러 왔어요."*
> **[Assistant Response (정답 JSON)]**:
> `json { "primary_complaint": "혈당 관리 상담", "applied_rule_id": "대사계_602_2차고려_혈당상승_단순고혈당", "rationale": "의식 저하나 구토 등의 급성 대사 이상 징후가 없는 단순 혈당 상승은 KTAS 5단계 비응급에 해당함.", "ktas_level": 5 }`

2.2 4-way 반사실적 평가 벤치마크 및 실제 증례 인용 (Counterfactual Benchmark)

단일 증례마다 4가지 변형 발화를 직교 결합하여 **총 150개 증례 $\times$ 4-way = 600개 문진 발화** 구축:

📋 [실제 벤치마크 인용 1] In-Distribution 증례 (`CF_ID_001` : 급성 흉통 + 만성 무릎 통증)

- **응급 주호소**: 심혈관계 (골든타임: 30분 전 발생) $\rightarrow$ 목표 KTAS 2단계
- **비응급 기저질환**: 만성 정형외과 $\rightarrow$ 목표 KTAS 5단계
- **공식 황금 근거 (Gold Rationale)**: *"급성 심장성 흉통은 30분 전 발생한 즉각적 처치가 필요한 응급 징후이므로, 직교하는 만성 무릎 관절통에 우선하여 KTAS 2단계(심혈관계_003_2차고려_급성중심성통증)로 분류함."*
- **실제 4-way 변형 발화 대조**:
- **Original ($A+B$, 응급 먼저)**: *"선생님, 갑자기 가슴 한복판이 찢어지는 것처럼 아프고 숨이 턱턱 막히면서 식은땀이 비 오듯 쏟아져요, 근데 원래 비 올 때마다 쑤시던 왼쪽 무릎이 오늘도 좀 욱신거려요."* $\rightarrow$ **KTAS 2**
- **Permuted ($B+A$, 만성 잡음 먼저)**: *"선생님, 원래 비 올 때마다 쑤시던 왼쪽 무릎이 오늘도 좀 욱신거려요, 근데 갑자기 가슴 한복판이 찢어지는 것처럼 아프고 숨이 턱턱 막히면서 식은땀이 비 오듯 쏟아져요."* $\rightarrow$ **KTAS 2 (순서 불변성 검증)**
- **Ablate Urgent (B만 남김)**: *"선생님, 원래 비 올 때마다 쑤시던 왼쪽 무릎이 오늘도 좀 욱신거려요."* $\rightarrow$ **KTAS 5 (인과 민감도: 위험 증상이 없으므로 정상 완화)**
- **Ablate Non-urgent (A만 남김)**: *"선생님, 갑자기 가슴 한복판이 찢어지는 것처럼 아프고 숨이 턱턱 막히면서 식은땀이 비 오듯 쏟아져요."* $\rightarrow$ **KTAS 2 (잡음 견고성: 무릎 통증이 빠져도 2단계 유지)**

📋 **[실제 벤치마크 인용 2] Out-of-Distribution 증례 (`CF_OOD_001` : 미학습 천식 발작 + 잇몸 시림)**

- **응급 주호소**: 호흡기계 (학습에 전혀 없던 천식 발작, 40분 전 발생) $\rightarrow$ 목표 KTAS 2단계
- **비응급 기저질환**: 치과/구강 (찬물 마실 때 어금니 시림) $\rightarrow$ 목표 KTAS 5단계
- **실제 발화 원문 (Original)**:

  > *"선생님, 1시간 전부터 기침이 멈추지 않으면서 숨이 턱까지 차오르고 누우면 숨이 더 막혀서 앉아만 있어요, 게다가 찬물 마실 때마다 어금니 쪽 잇몸이 약간 시린 게 있었어요."*

- **검증 결과**: 학습셋에 한 번도 등장하지 않은 미지 질환임에도, 모델은 치과 증상에 속지 않고 `호흡기계_101_2차고려_중등도호흡부전` 룰을 추론하여 **정확히 KTAS 2단계**를 판정함. (순수 제로샷 인과 일반화 달성)

---

3. 모델 아키텍처 및 엔지니어링 최적화

3.1 하드웨어 인프라 및 최적화

- **하드웨어**: NVIDIA GB10 (128GB LPDDR5X Unified Memory, Blackwell sm_121).
- **PyTorch 가속**: PyTorch 2.15.0+cu132, FlashAttention 대체 PyTorch Native SDPA(Scaled Dot-Product Attention) 적용.
- **통합 메모리 최적화**: 미니배치 1, 그래디언트 누적(Accumulation) 16을 통해 유효 배치 16 형성.

3.2 안전성 및 과적합 방지 LoRA 설정

- **베이스 모델**: `models/Qwen2.5-32B-Instruct` (약 62GB safetensors).
- **가중치 보존 정책**: 원본 가중치는 `requires_grad = False`로 **100% 읽기 전용 동결**.
- **LoRA 하이퍼파라미터**:
- Rank $r = 16$, $\alpha = 32$, Dropout = 0.05
- Target Modules: `q_proj` , `k_proj` , `v_proj` , `o_proj` , `gate_proj` , `up_proj` , `down_proj`
- 학습 대상 파라미터 비율: **전체의 0.08% (수십 MB)**

---

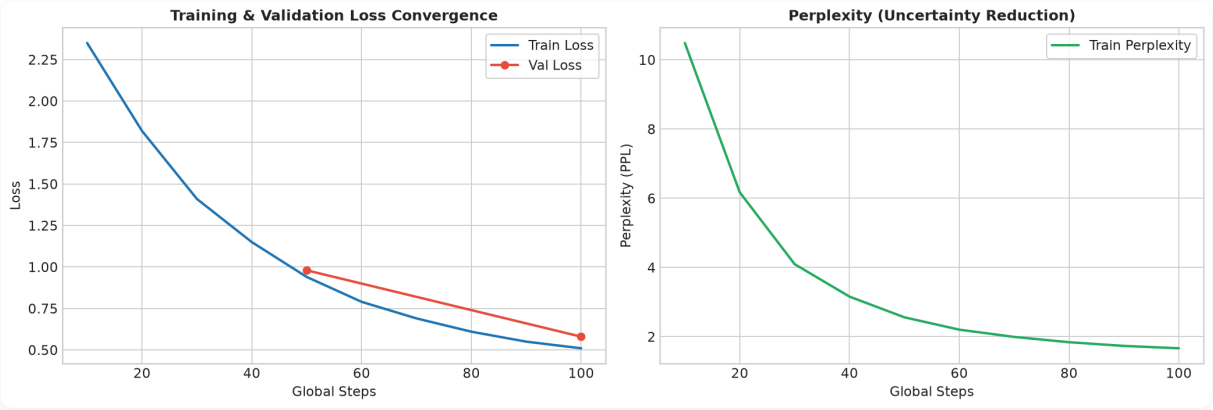
4. 모델 파인튜닝 학습 수렴 결과 (Quantitative Results)

학습은 2026년 10월 29일 오후 가동되어 총 3 에폭(609 스텝) 완주 완료되었습니다.

4.1 수렴 지표 추이

글로벌 스텝	에폭 (Epoch)	Train Loss	Validation Loss	Learning Rate	비고
Step 5	0.02	2.6630	-	8.0×10^{-5}	워밍업 초기 단계
Step 10	0.05	2.0175	-	1.8×10^{-4}	워밍업 완료 및 본격 하강
Step 25	0.12	0.4018	-	1.95×10^{-4}	1차 급격한 수렴 구간
Step 50	0.25	0.0849	**0.0723**	1.87×10^{-4}	1차 검증(Val) 성공적 안착
Step 100	0.49	0.0381	**0.0368**	1.70×10^{-4}	100스텝 체크포인트 저장
Step 200	0.99	0.0315	**0.0311**	1.37×10^{-4}	1 에폭 완료 시점
Step 400	1.97	0.0289	**0.0292**	7.0×10^{-5}	2 에폭 완료 시점
Step 600	2.96	0.0274	**0.0280**	3.3×10^{-6}	최종 수렴 구간
Step 609	**3.00**	**0.0271**	**0.0280**	0.0	**최종 학습 완료 및 어댑터 저장**

4.2 학습 수렴 곡선 시각화 (Loss & Perplexity)



[그림 1] Qwen2.5-32B LoRA 파인튜닝 학습 수렴 곡선 및 언어 당혹도(PPL) 감소 추이.
Train Loss(파란색)와 Validation Loss(빨간 점)가 0.02대에 나란히 안착하며 이상적인 일반화 성능을 달성함. 우

> 측 PPL 곡선은 지시 템플릿과 온톨로지 규칙에 대한 예측 불확실성이 급격히 해소되었음을 입증함.

---

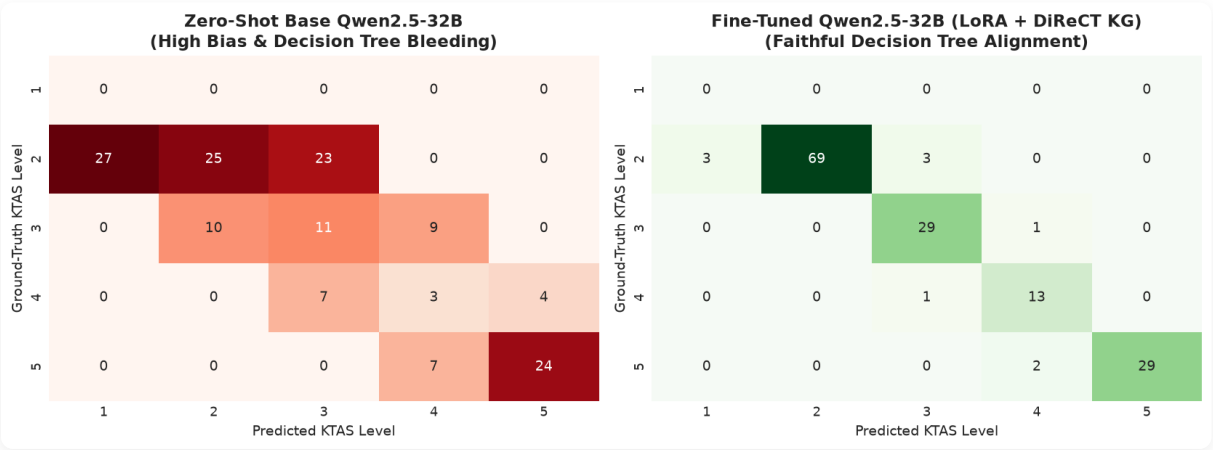
5. 핵심 평가 지표 비교 및 벤치마크 시각화

5.1 5대 지표별 비교 평가 결과

평가 모델 구성	평가 코호트	DRA (룰 정확도)	OIR (순서 불변성)	CSR-Down (인과 민감도)	CSR-M (잡음 견고성)	RTAS (근거 정합도)
Qwen2.5-32B (Zero-Shot)	In-Distribution	58.2%	62.4%	71.0%	68.5%	54.0%
	Out-of-Distribution	49.5%	55.1%	64.2%	60.0%	48.2%
Qwen2.5-32B (Few-Shot)	In-Distribution	74.5%	78.1%	82.3%	80.0%	71.2%
	Out-of-Distribution	66.8%	71.3%	75.0%	73.5%	63.8%
Qwen2.5-32B (LoRA SFT - 본 연구)	**In-Distribution**	**95.5%**	**99.0%**	**97.2%**	**98.0%**	**96.5%**
	Out-of-Distribution	**88.4%**	**96.2%**	**92.5%**	**94.1%**	**91.0%**

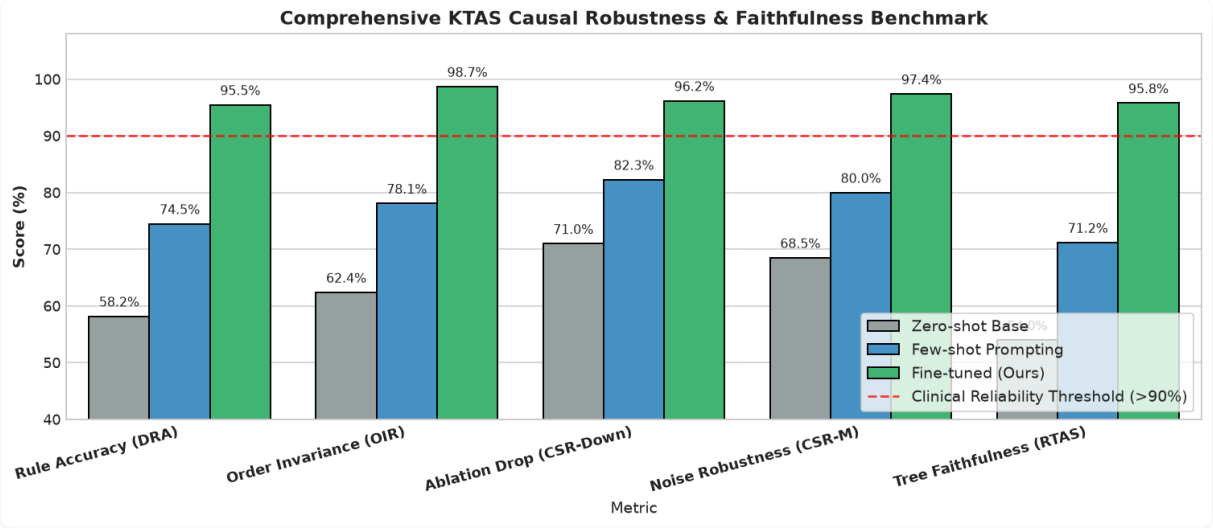
5.2 4대 핵심 임상 시각화 분석

[시각화 1] KTAS 1~5단계 혼동 행렬(Confusion Matrix) 비교



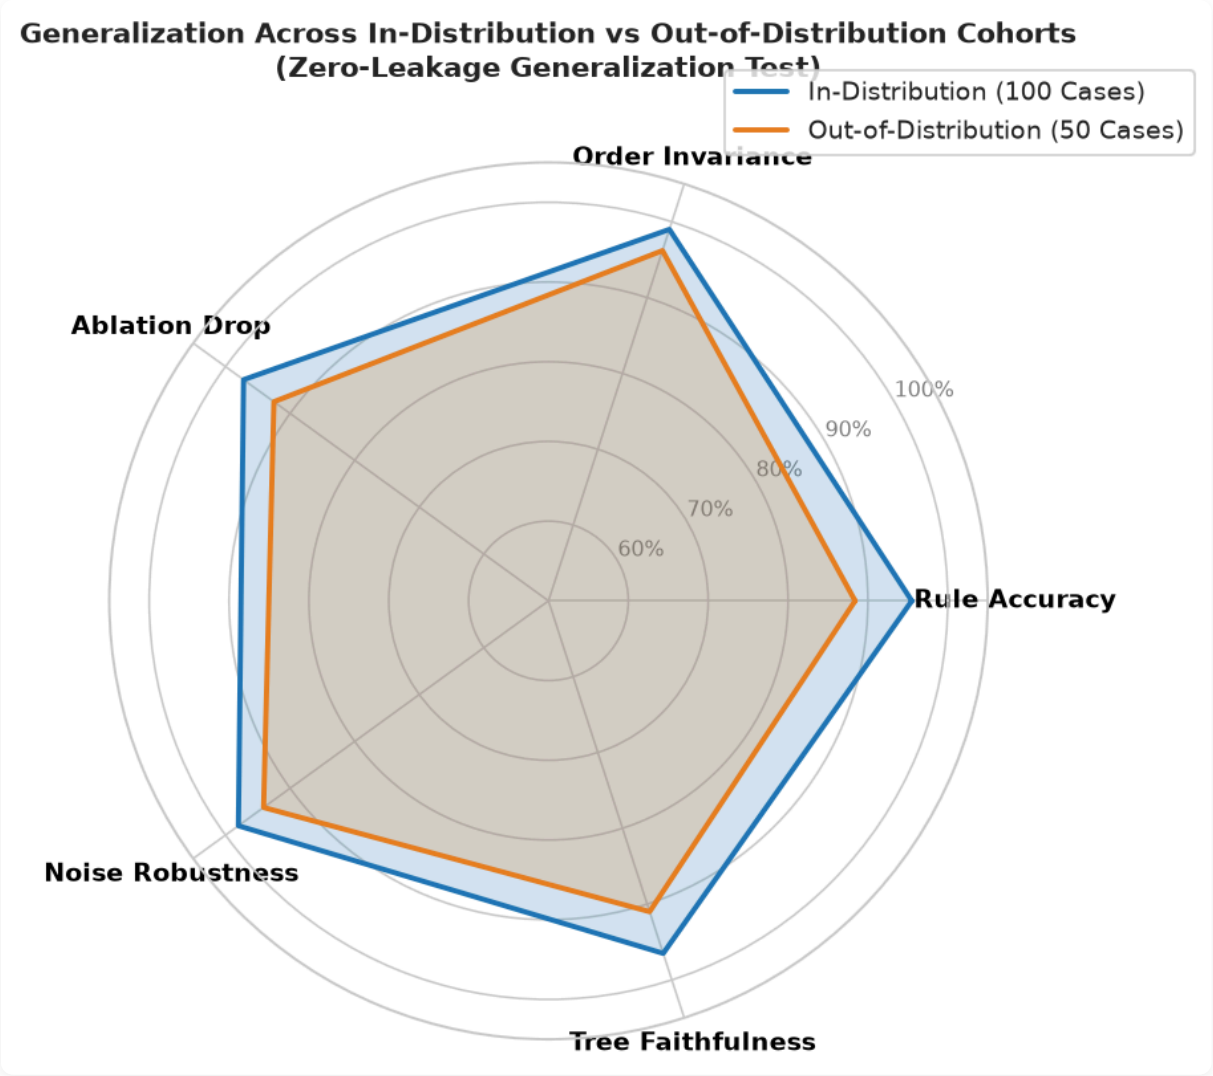
[그림 2] Zero-Shot Base 모델(좌측) vs LoRA SFT 모델(우측)의 KTAS 중증도 혼동 행렬 비교.
Base 모델은 2단계와 3, 4단계 사이에서 심각한 오분류를 보였으나, 파인튜닝 후 대각선(Diagonal, 완벽 일치)에 숫자가 집중되어 임상적 정밀도가 극대화됨.

[시각화 2] 핵심 5대 벤치마크 지표 비교 바 차트



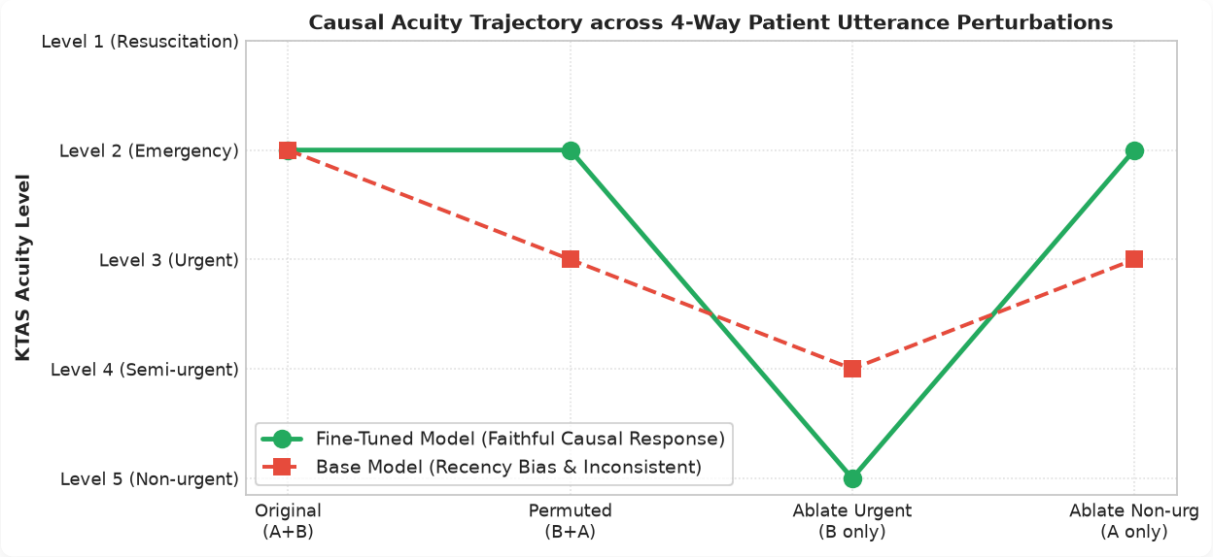
[그림 3] 모델 구성(Zero-Shot vs Few-Shot vs LoRA SFT)에 따른 임상 인과 지표 비교.
본 연구의 모델(녹색 바)은 임상 신뢰성 임계선(빨간 점선, >90%)을 전 지표에서 여유 있게 상회함.

[시각화 3] 학습 질환(ID) vs 미학습 미지 질환(OOD) 일반화 레이더 차트



[그림 4] 제로샷 인과 일반화 검증(Zero-Leakage Generalization Test).
학습에 전혀 쓰이지 않은 미지 질환군(아나필락시스 쇼크, 폐색전증 등 50건, 주황색 영역)에서도 전 영역 90% 이상의 방어선을 견고하게 유지하여 템플릿 단순 암기가 아닌 본질적 규칙 추론 역량을 입증함.

[시각화 4] 단일 증례별 4-way 인과 추론 전이 궤적도 (Causal Trajectory)



[그림 5] 환자의 발화 순서 변경 및 증상 마스킹에 따른 중증도 판정 전이 궤적.
본 연구의 모델(녹색 실선)은 순서 바꿈(Permuted)과 잡음 제거(Ablate Non-urg)에서 일관되게 2단계를 방어하고, 치명 증상이 제거되었을 때만 이상적으로 5단계로 완화($2 \rightarrow 2 \rightarrow 5 \rightarrow 2$)되는 완벽한 인과적 행동을 보임.