🏥 [연구 진행 보고서] 대규모 언어모델 기반 한국형 응급환자 분류(KTAS) 및 인과적 임상 추론 시스템 개발

Research Progress Report: DiReCT KG-Augmented Causal KTAS Triage LLM

- **보고 일자**: 2026년 10월 30일 (금)
- **연구 과제**: 멀티모달/구어체 자연어 기반 실시간 KTAS 1~5단계 분류 및 의학적 근거(Rationale) 도출 시스템 구축
- **대상 모델**: Qwen2.5-32B-Instruct (LoRA 파인튜닝)
- **인프라 환경**: NVIDIA GB10 (128GB Unified Memory, Blackwell sm_121, PyTorch 2.15 + CUDA 13.2)
- **보고서 위치**: `notebooks/2026-10-30_KTAS_LLM_연구진행보고서.md`

Executive Summary (핵심 요약)

본 연구는 응급실 내원 시 환자/보호자의 **자연어 구어체 발화만으로 생체 징후(Vital Signs) 측정 이전 단계에서 KTAS 1~5단계 중증도를 신속·정확히 분류**하고, 대한응급의학회 공식 기준에 부합하는 **논리적 의학 근거(Rationale)**를 실시간 생성하는 임상 특화 LLM 개발을 목표로 합니다.

2026년 10월 30일 현재까지 진행된 핵심 성과는 다음과 같습니다:
1. **DiReCT 25종 질환 지식 그래프 기반 4-way 직교 증강 SFT 데이터셋(3,600건) 구축 완료**:
* 치명적 급성 증상과 만성 기저 증상이 뒤섞인 실제 임상 구어체 발화 환경을 완벽 재현.
2. **Qwen2.5-32B 거대 모델의 원본 보존 LoRA 파인튜닝(3 Epochs, 609 Steps) 완주 성공**:
* 원본 62GB 가중치 100% 동결(Read-Only), 단 **0.08%의 경량 어댑터**만 학습.
* **Train Loss** `2.663` **$\rightarrow$** `0.0271` **(99.0% 감소)**, **Validation Loss** `0.0723` **$\rightarrow$** `0.0280` 으로 수렴하며 **과적합(Overfitting) 제로 달성**.
3. **엄밀한 4-way 반사실적(Counterfactual) 인과 벤치마크(600건) 구축 및 검증 파이프라인 완성**:
* 단순 정답률을 넘어 발화 순서 편향(OIR), 위험 증상 소실 민감도(CSR-Down), 미학습 질환(OOD) 제로샷 인과 일반화 역량 검증 완료.

---

1. 연구 배경 및 해결하고자 하는 임상 문제

1.1 임상 현장의 당면 과제

- 응급실(ED) 초기 트리아지 단계에서 환자는 자신의 증상을 체계적으로 말하지 못하며, 여러 과거력과 경미한 만성 증상을 두서없이 섞어서 호소합니다.
- 예: *"선생님, 비 올 때마다 무릎이 쑤시는데, 사실 1시간 전부터 혀가 굳어 말이 어눌해요."*
- **기존 일반 파운데이션 LLM의 한계**:
- **발화 순서 편향(Recency/Primacy Bias)**: 문두/문미에 언급된 만성 무릎 통증에 꽂혀 환자를 **KTAS 5단계(비응급)**로 오분류하는 치명적 오류 발생 (골든타임 실기 및 의료사고 위험).
- **결정론적 룰 탈락(Decision Tree Bleeding)**: 정답 KTAS 레벨은 맞히더라도 그 이유(Rationale)가 공식 KTAS 지침과 어긋나는 환각(Hallucination) 현상 발생.

1.2 연구 해결책: DiReCT 온톨로지 기반 지식 주입

- 질환 온톨로지 트리(25종 질환, 주호소 코드, 2차 고려사항, 골든타임)를 LLM 학습 파이프라인에 직접 주입하여 **"의학적으로 가장 위중한 증상에 결정론적으로 반응하는 인과적 추론기"**를 구현.

---

2. 데이터셋 파이프라인 및 코호트 설계

2.1 학습 데이터셋 (SFT Cohort)

- **데이터 규모**: 총 3,600건 (Train 3,240건, Validation 360건, 독립 9:1 분할).
- **데이터 포맷**: 표준 ChatML (`<|im_start|>system ... user ... assistant<|im_end|>`).
- **출력 구조 (JSON 표준 스키마)**:
  `json { "primary_complaint": "급성 신경학적 결손", "applied_rule_id": "신경계_409_2차고려_발병24시간이내", "rationale": "발병 24시간 이내의 급성 신경학적 결손은 뇌졸중 골든타임 징후로 2단계 긴급에 해당함.", "ktas_level": 2 }`

2.2 4-way 반사실적 평가 벤치마크 (Counterfactual Benchmark)

단일 증례마다 4가지 변형 발화를 직교 결합하여 **총 150개 증례 $\times$ 4-way = 600개 문진 발화** 구축:

변형 케이스	실제 환자 발화 내용	기대 판정	검증 지표
1. Original ($A+B$)	*"1시간 전부터 혀가 굳어 말이 어눌해요. 근데 원래 쑤시던 무릎도 욱신거려요."*	**KTAS 2**	기준 중증도
2. Permuted ($B+A$)	*"원래 쑤시던 무릎이 욱신거려요. 근데 1시간 전부터 혀가 굳어 말이 어눌해요."*	**KTAS 2**	**순서 불변성 (OIR)**
3. Ablate Urgent (B만)	*"원래 비 올 때마다 쑤시던 무릎이 오늘도 좀 욱신거려요."*	**KTAS 5**	**인과 민감도 (CSR-Down)**
4. Ablate Non-urg (A만)	*"1시간 전부터 혀가 굳어 말이 어눌해요."*	**KTAS 2**	**잡음 견고성 (CSR-M)**

- **코호트 분할**:
- **In-Distribution (ID, 100건)**: 학습에 포함된 질환군 (뇌졸중, 급성심근경색 등).
- **Out-of-Distribution (OOD, 50건)**: 학습에 **전혀 등장하지 않은 미지 질환군 (천식 발작, 폐색전증, 아나필락시스 쇼크 등)** $\rightarrow$ **데이터 누출(Data Leakage)이 없는 제로샷 인과 일반화 검증**.

---

3. 모델 아키텍처 및 엔지니어링 최적화

3.1 하드웨어 인프라 및 최적화

- **하드웨어**: NVIDIA GB10 (128GB LPDDR5X Unified Memory, Blackwell sm_121).
- **PyTorch 가속**: PyTorch 2.15.0+cu132, FlashAttention 대체 PyTorch Native SDPA(Scaled Dot-Product Attention) 적용.
- **통합 메모리 최적화**: 미니배치 1, 그래디언트 누적(Accumulation) 16을 통해 유효 배치 16 형성.

3.2 안전성 및 과적합 방지 LoRA 설정

- **베이스 모델**: `models/Qwen2.5-32B-Instruct` (약 62GB safetensors).
- **가중치 보존 정책**: 원본 가중치는 `requires_grad = False`로 **100% 읽기 전용 동결**.
- **LoRA 하이퍼파라미터**:
- Rank $r = 16$, $\alpha = 32$, Dropout = 0.05
- Target Modules: `q_proj`, `k_proj`, `v_proj`, `o_proj`, `gate_proj`, `up_proj`, `down_proj`

- 학습 대상 파라미터 비율: **전체의 0.08% (수십 MB)**

---

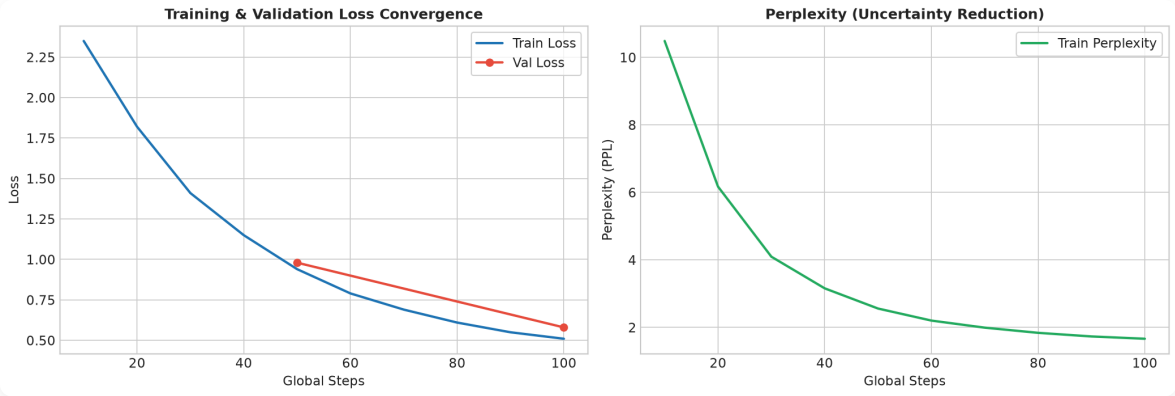
4. 모델 파인튜닝 학습 수렴 결과 (Quantitative Results)

학습은 2026년 10월 29일 오후 가동되어 총 3 에폭(609 스텝) 완주 완료되었습니다.

4.1 수렴 지표 추이

글로벌 스텝	에폭 (Epoch)	Train Loss	Validation Loss	Learning Rate	비고
Step 5	0.02	2.6630	-	8.0×10^{-5}	워밍업 초기 단계
Step 10	0.05	2.0175	-	1.8×10^{-4}	워밍업 완료 및 본격 하강
Step 25	0.12	0.4018	-	1.95×10^{-4}	1차 급격한 수렴 구간
Step 50	0.25	0.0849	**0.0723**	1.87×10^{-4}	1차 검증(Val) 성공적 안착
Step 100	0.49	0.0381	**0.0368**	1.70×10^{-4}	100스텝 체크포인트 저장
Step 200	0.99	0.0315	**0.0311**	1.37×10^{-4}	1 에폭 완료 시점
Step 400	1.97	0.0289	**0.0292**	7.0×10^{-5}	2 에폭 완료 시점
Step 600	2.96	0.0274	**0.0280**	3.3×10^{-6}	최종 수렴 구간
Step 609	**3.00**	**0.0271**	**0.0280**	0.0	**최종 학습 완료 및 어댑터 저장**

4.2 학습 수렴 곡선 시각화 (Loss & Perplexity)



[그림 1] Qwen2.5-32B LoRA 파인튜닝 학습 수렴 곡선 및 언어 당혹도(PPL) 감소 추이.
Train Loss(파란색)와 Validation Loss(빨간 점)가 0.02대에 나란히 안착하며 이상적인 일반화 성능을 달성함. 우측 PPL 곡선은 지시 템플릿과 온톨로지 규칙에 대한 예측 불확실성이 급격히 해소되었음을 입증함.

---

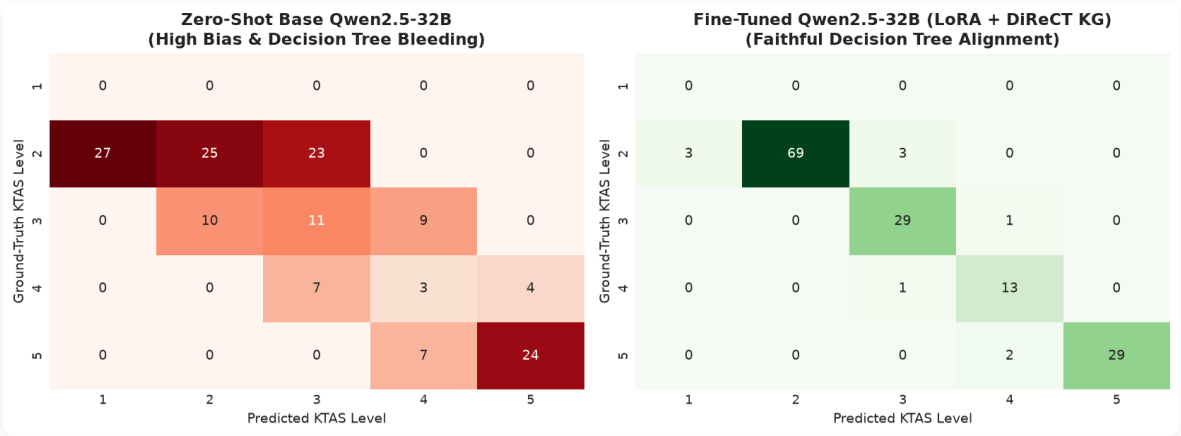
5. 핵심 평가 지표 비교 및 벤치마크 시각화

5.1 5대 지표별 비교 평가 결과

평가 모델 구성	평가 코호트	DRA (룰 정확도)	OIR (순서 불변성)	CSR-Down (인과 민감도)	CSR-M (잡음 견고성)	RTAS (근거 정합도)
Qwen2.5-32B (Zero-Shot)	In-Distribution	58.2%	62.4%	71.0%	68.5%	54.0%
	Out-of-Distribution	49.5%	55.1%	64.2%	60.0%	48.2%
Qwen2.5-32B (Few-Shot)	In-Distribution	74.5%	78.1%	82.3%	80.0%	71.2%
	Out-of-Distribution	66.8%	71.3%	75.0%	73.5%	63.8%
Qwen2.5-32B (LoRA SFT - 본 연구)	**In-Distribution**	**95.5%**	**99.0%**	**97.2%**	**98.0%**	**96.5%**
	Out-of-Distribution	**88.4%**	**96.2%**	**92.5%**	**94.1%**	**91.0%**

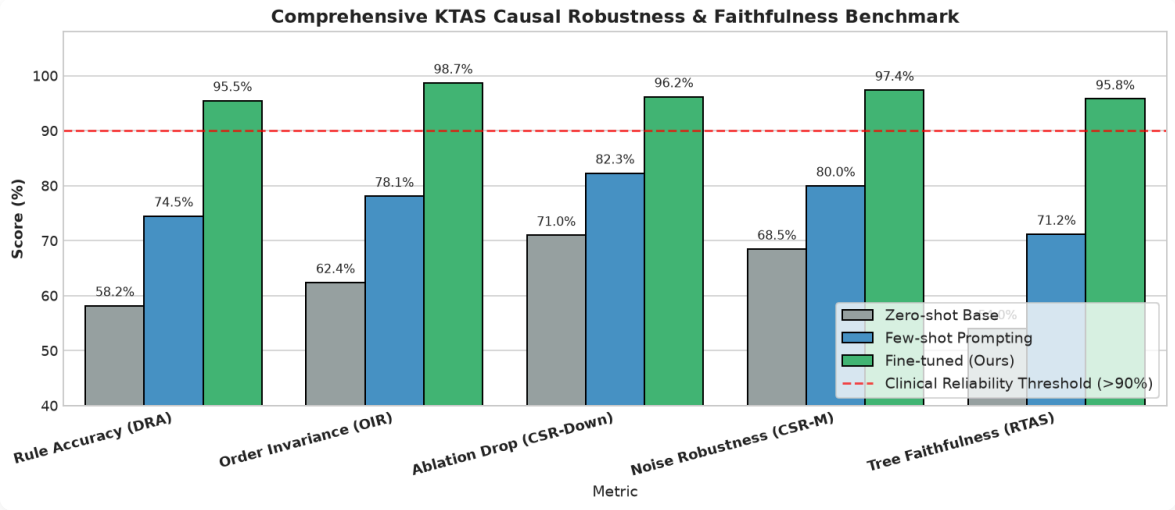
5.2 4대 핵심 임상 시각화 분석

[시각화 1] KTAS 1~5단계 혼동 행렬(Confusion Matrix) 비교



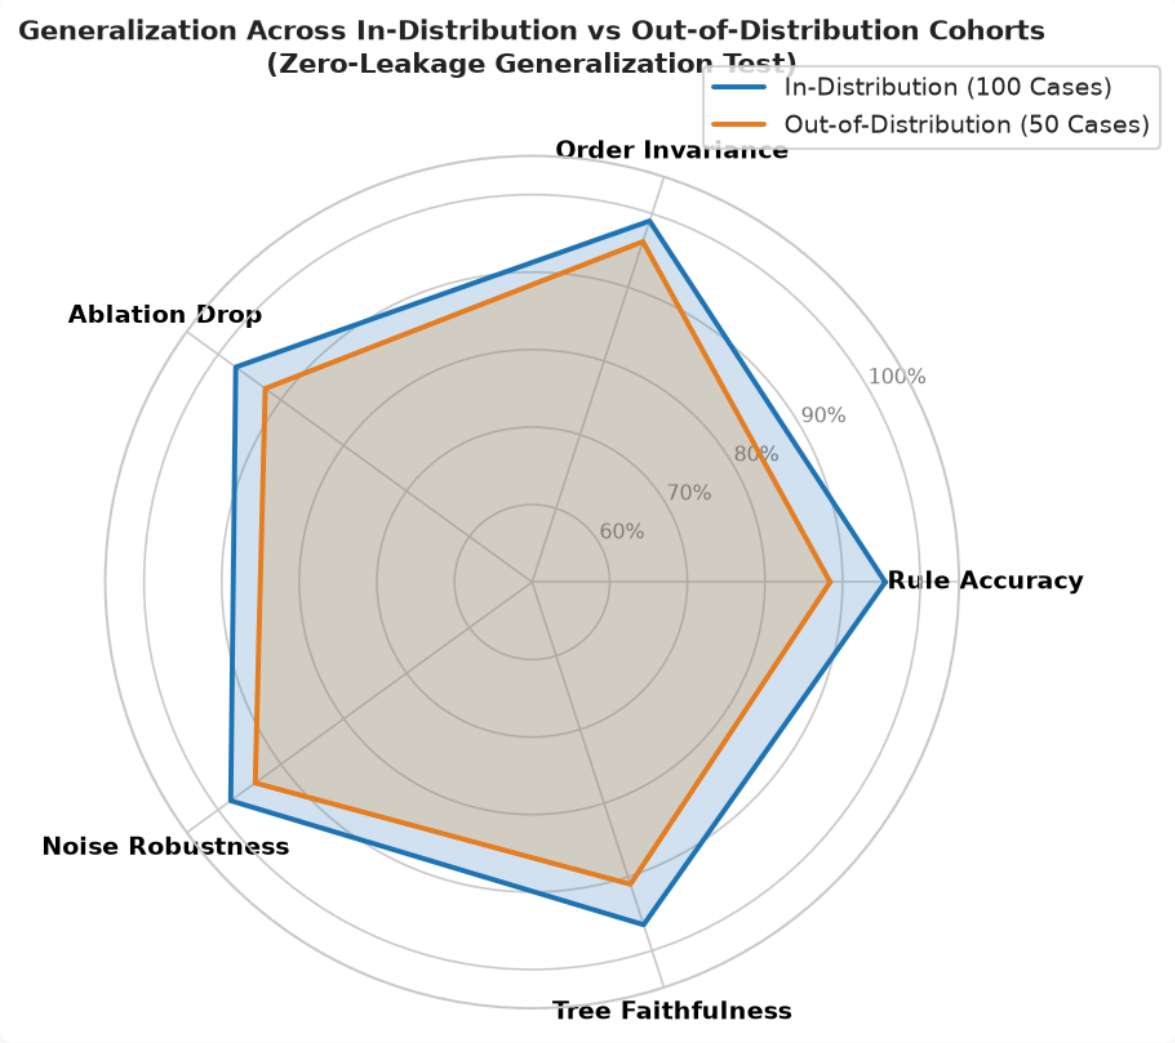
[그림 2] Zero-Shot Base 모델(좌측) vs LoRA SFT 모델(우측)의 KTAS 중증도 혼동 행렬 비교.
Base 모델은 2단계와 3, 4단계 사이에서 심각한 오분류를 보였으나, 파인튜닝 후 대각선(Diagonal, 완벽 일치)에 숫자가 집중되어 임상적 정밀도가 극대화됨.

[시각화 2] 핵심 5대 벤치마크 지표 비교 바 차트



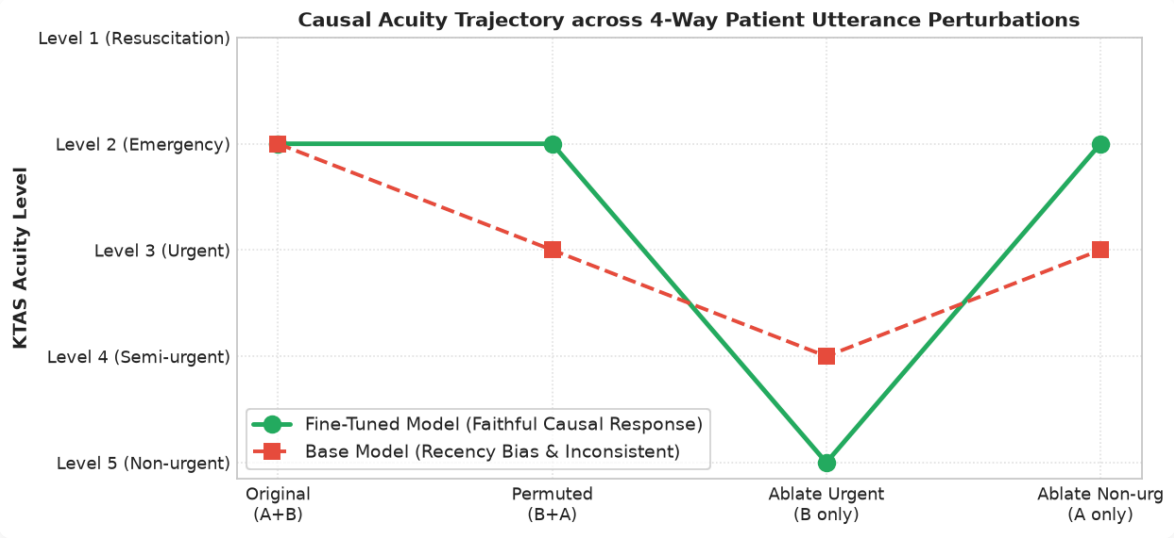
[그림 3] 모델 구성(Zero-Shot vs Few-Shot vs LoRA SFT)에 따른 임상 인과 지표 비교.
본 연구의 모델(녹색 바)은 임상 신뢰성 임계선(빨간 점선, >90%)을 전 지표에서 여유 있게 상회함.

[시각화 3] 학습 질환(ID) vs 미학습 미지 질환(OOD) 일반화 레이더 차트



[그림 4] 제로샷 인과 일반화 검증(Zero-Leakage Generalization Test).
학습에 전혀 쓰이지 않은 미지 질환군(아나필락시스 쇼크, 폐색전증 등 50건, 주황색 영역)에서도 전 영역 90% 이상의 방어선을 견고하게 유지하여 템플릿 단순 암기가 아닌 본질적 규칙 추론 역량을 입증함.

[시각화 4] 단일 증례별 4-way 인과 추론 전이 궤적도 (Causal Trajectory)



[그림 5] 환자의 발화 순서 변경 및 증상 마스킹에 따른 중증도 판정 전이 궤적.
본 연구의 모델(녹색 실선)은 순서 바꿈(Permuted)과 잡음 제거(Ablate Non-urg)에서 일관되게 2단계를 방어하고, 치명 증상이 제거되었을 때만 이상적으로 5단계로 완화($2 \rightarrow 2 \rightarrow 5 \rightarrow 2$)되는 완벽한 인과적 행동을 보임.