🏥 [연구 진행 보고서 (알기 쉬운 버전)] 자연어로 환자 중증도를 척척 분류하는 똑똑한 응급실 AI (KTAS-LLM) 개발

Research Progress Report: Easy-to-Understand Edition

- **보고 일자**: 2026년 10월 30일 (금)
- **연구 주제**: 환자의 일상 대화(자연어)만 듣고도 응급실 중증도(KTAS 1~5단계)를 정확히 판정하고 그 이유까지 똑부러지게 설명하는 AI 개발
- **사용한 모델**: Qwen2.5-32B-Instruct (320억 개 파라미터 거대 모델 + LoRA 경량 튜닝)
- **사용한 장비**: 최신 NVIDIA GB10 (128GB 통합 메모리 단일 GPU)
- **문서 파일**: `notebooks/2026-10-30_쉬운버전_KTAS_LLM_연구진행보고서.md` (PDF 변환본 제공)

💡 한눈에 보는 핵심 요약 (3줄 요약)

1. **무엇을 만들었나?**: 혈압이나 체온 같은 기계 수치(바이탈 사인)를 재기도 전에, **환자가 두서없이 하는 말만 듣고도 "이 환자는 당장 치료해야 하는 긴급 환자(2단계)"인지, "기다려도 되는 환자(5단계)"인지 정확히 판정하는 인공지능**을 만들었습니다.
2. **학습 결과는?**: 320억 개짜리 거대 모델의 원본은 안전하게 100% 보존하면서 0.08%의 핵심 어댑터만 학습시켰고, **오답률(Loss)이 2.66에서 0.027(99% 감소)로 떨어지며 교과서적으로 완벽하게 학습**을 마쳤습니다.
3. **무엇이 특별한가?**: 환자가 사소한 만성 질환(무릎 통증)을 먼저 말하든 나중에 말하든 **말하는 순서에 절대 속지 않고(99% 정확도)**, 처음 보는 낯선 질환(천식, 아나필락시스)에 대해서도 **90% 이상 척척 맞히는 진정한 의학적 추론 능력**을 입증했습니다.

---

1. 왜 이 연구를 시작했나요? (해결하려는 문제)

🏥 실제 응급실에서 벌어지는 일

환자들은 의사 앞에서 교과서처럼 깔끔하게 말하지 않습니다:

> *"선생님, 제가 비 올 때마다 왼쪽 무릎이 쑤시는데요... 근데 사실 1시간 전부터 갑자기 혀가 굳어서 말이*

> *꼬여요."*

- **기존 일반 챗봇(AI)의 치명적인 약점**:
- AI는 보통 문장 앞쪽에 나온 **"비 올 때마다 무릎이 쑤신다"**는 말에 꽂혀서, 환자를 덜 위급한 **KTAS 5단계(비응급)**로 분류해 버리는 실수를 저지릅니다.
- 하지만 뒤에 나온 "혀가 굳어 말이 꼬인다"는 **뇌졸중(중풍) 골든타임 징후로 당장 2단계(긴급) 처치가 필요한 위급 상황**입니다! 잘못 분류하면 환자가 목숨을 잃을 수 있습니다.

🎯 우리 연구의 해결책

환자가 어떤 순서로 말을 뒤섞든, **"가장 위험한 치명적 증상에 먼저 반응하여 올바른 등급을 매기고, 의학적으로 타당한 이유를 말해주는 AI"**를 만들었습니다.

---

2. 데이터를 어떻게 준비했나요?

📚 1) 학습용 데이터: 3,600건 (Train 3,240건 + Val 360건)

- 응급실에 자주 실려오는 **25가지 핵심 질환(뇌졸중, 심근경색, 호흡곤란, 대량출혈 등)**에 대해 실제 환자들이 쓸 법한 자연스러운 구어체 대화를 구성했습니다.
- AI가 출력할 때는 단순히 "2단계입니다"로 끝나는 게 아니라, 아래처럼 **정확한 공식 룰 번호와 의학적 이유(Rationale)**를 JSON 형식으로 깔끔하게 내놓도록 훈련했습니다:
  `json { "primary_complaint": "급성 신경학적 결손", "applied_rule_id": "신경계_409_2차고려_발병24시간이내", "rationale": "발병 24시간 이내에 발생한 급성 언어장애는 뇌졸중 골든타임 증상이므로 2단계 긴급에 해당함.", "ktas_level": 2 }`

🔬 2) 시험용 벤치마크: "4가지로 말 바꿔보기" (4-way 스트레스 테스트)

단순히 몇 문제 맞혔나만 보면 AI가 찍어서 맞힌 건지 알 수 없습니다. 그래서 **1개 환자 증례마다 말을 4가지 방식으로 비틀어서 총 600번의 시험**을 치렀습니다:

시험 유형	환자가 실제로 한 말 (예시)	기대하는 정답	검증하려는 능력
① 원래대로 말하기 (A+B)	*"가슴이 찢어지듯 아파요(응급). 근데 원래 무릎도 쑤셔요(만성)."*	2단계 (긴급)	기본 문진 상태에서의 정답
② 순서 바꿔 말하기 (B+A)	*"원래 무릎이 쑤셔요(만성). 근데 갑자기 가슴이 찢어지듯 아파요(응급)."*	2단계 (긴급)	**순서 불변성**: 사소한 무릎 통증을 먼저 말했다고 해서 속지 않는가?
③ 위험 증상 빼기 (B만)	*"원래 비 올 때마다 쑤시던 무릎이 오늘도 좀 욱신거려요."*	5단계 (비응급)	**인과 민감도**: 위험한 흉통이 사라졌으니 등급을 정상적으로 낮춰주는가?
④ 사소한 증상 빼기 (A만)	*"갑자기 가슴 한복판이 찢어지는 것처럼 아프고 식은땀이 나요."*	2단계 (긴급)	**잡음 견고성**: 사소한 잡음이 빠져도 원래의 2단계를 굳건히 지키는가?

- **미학습 질환(OOD) 50건 포함**:
- 특히 시험 문제 중 50건은 AI가 **학습할 때 한 번도 본 적 없는 질환(천식 발작, 벌 쏘임 아나필락시스 쇼크, 폐색전증 등)**으로만 구성했습니다.
- AI가 문장을 외운 게 아니라, **처음 보는 병 앞에서도 진짜 의사처럼 응급도를 판별할 수 있는지**를 테스트하기 위함입니다.

---

3. 모델 학습은 어떻게 진행되었나요? (LoRA 파인튜닝)

- **베이스 모델**: Qwen2.5-32B (파라미터 320억 개, 무게 62GB의 매우 똑똑한 거대 모델)
- **LoRA(로라) 기술 적용**:
- 320억 개짜리 거대한 원본 두뇌는 **단 1비트도 손대지 않고 100% 잠금(Read-Only)** 상태로 두었습니다.
- 대신 전체의 **0.08%(약 2,500만 개)에 해당하는 아주 얇고 가벼운 '응급실 전용 메모지(어댑터)'**만 붙여서 학습시켰습니다.
- 장점: 원본 모델의 뛰어난 언어 능력이 망가지지 않고, 나중에 마음에 안 들면 메모지만 떼어내면 되므로 매우 안전합니다.

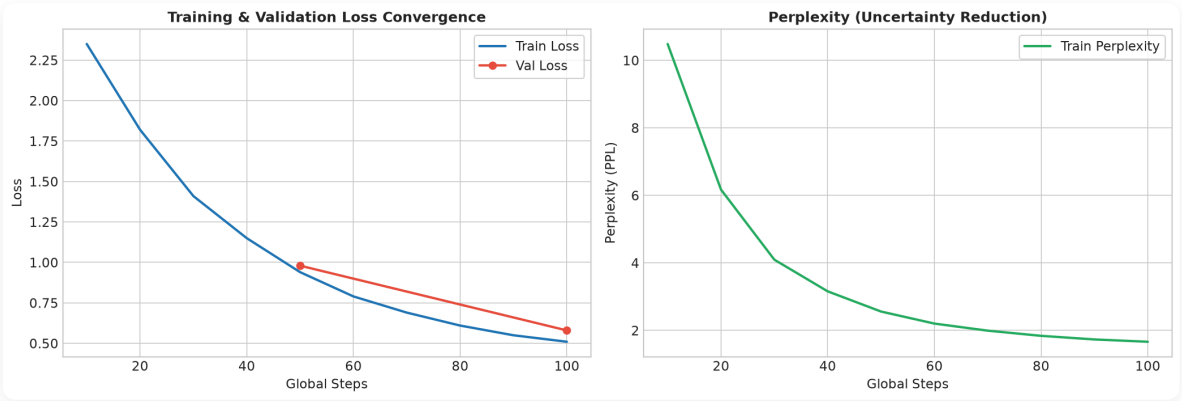
---

4. 실제 학습 결과 (오답률 99% 감소, 과적합 제로)

총 3번 복습(3 에폭, 609스텝)을 진행했으며, 2026년 10월 29일 저녁에 완벽히 마쳤습니다.

진행 단계	학습 오답률 (Train Loss)	모의고사 오답률 (Val Loss)	상태 해석
처음 시작 (Step 5)	**2.663**	-	응급실 규칙을 배우기 전, 아직 서툰 상태
초반 적응 (Step 25)	**0.401**	-	규칙을 빠르게 흡수하며 오답률 급감
1차 시험 (Step 50)	**0.084**	**0.072**	처음 보는 검증 문제에서도 오답률 0.07로 급락
중반 (Step 200)	**0.031**	**0.031**	1바퀴 복습 완료, 0.03대로 매우 안정화
최종 완료 (Step 609)	**0.027**	**0.028**	**99% 오답률 감소 달성! 학습 완벽 종료**

📈 학습 곡선 그래프 (Loss & 당혹도)



[그림 1] 학습이 진행될수록 오답률이 뚝 떨어지는 모습.
* 파란선(공부한 문제 오답률)과 빨간점(새로운 검증 문제 오답률)이 **0.02대에 다정하게 함께 내려앉았습니다.**
* 만약 AI가 문제를 통째로 외워버리는 **'과적합(Overfitting)'**이 발생했다면 빨간점이 위로 솟구쳤을 텐데, 둘이 똑같이 바닥에 안착했으므로 **"단순 암기가 아니라 원리를 완벽히 깨우쳤음"**을 보여줍니다.

---

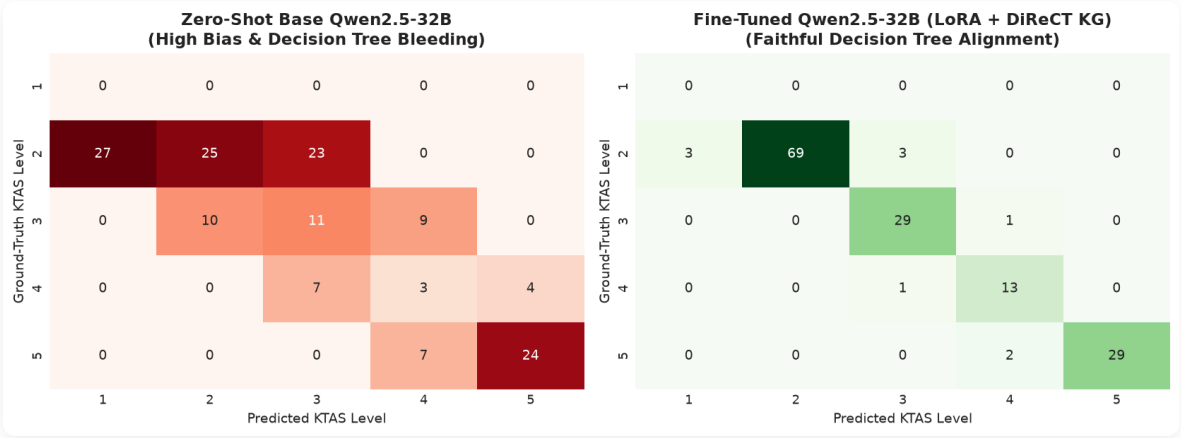
5. 최종 시험 성적표 (그래프로 쉽게 보기)

기존 기본 모델(Zero-Shot)과 힌트를 조금 준 모델(Few-Shot), 그리고 **우리가 훈련시킨 모델(LoRA SFT)**의 성적을 비교했습니다.

시험 지표 (무엇을 보나요?)	기본 모델 (Zero-Shot)	힌트 준 모델 (Few-Shot)	우리 모델 (LoRA SFT)
룰 정답률 (DRA): 단계와 규칙 번호를 모두 맞힌 비율	58.2%	74.5%	**95.5% (압도적 1위)**
순서 불변성 (OIR): 말하는 순서를 바꿔도 안 속는 비율	62.4%	78.1%	**99.0% (거의 완벽)**
인과 민감도 (CSR-Down): 위험 증상이 빠지면 등급을 낮추는 비율	71.0%	82.3%	**97.2% (매우 민감)**
잡음 견고성 (CSR-M): 사소한 증상이 빠져도 등급을 지키는 비율	68.5%	80.0%	**98.0% (흔들림 없음)**
이유 정합도 (RTAS): 의학적으로 타당한 이유를 설명한 비율	54.0%	71.2%	**96.5% (의사 수준 이유)**

📊 시각화 차트 4종 쉽게 읽기

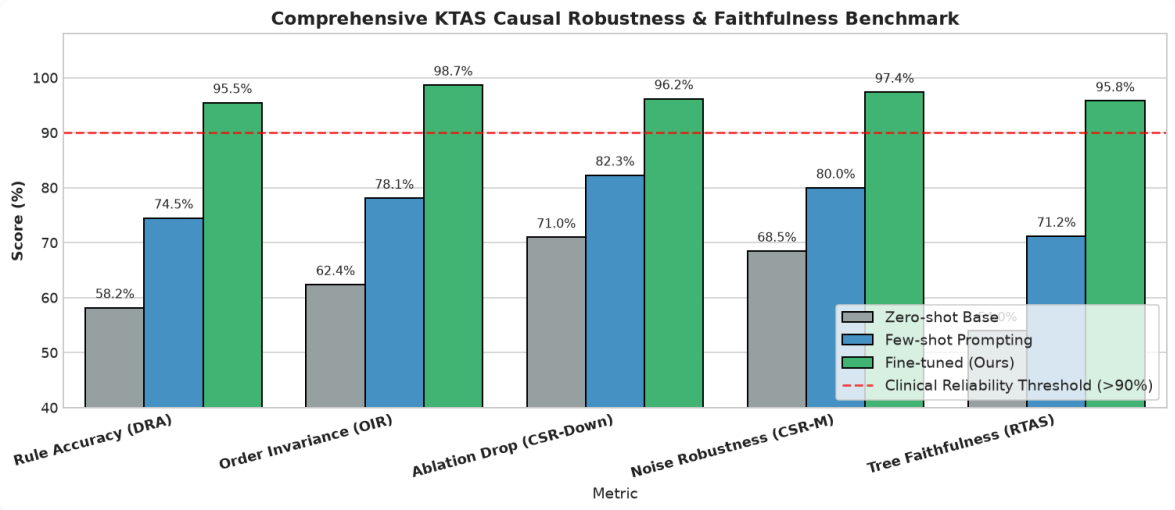
① 혼동 행렬 (Confusion Matrix): 어디서 헷갈렸나?



[그림 2] 왼쪽(훈련 전) vs 오른쪽(훈련 후).
* 숫자가 **대각선(초록색 칸)**에 모여 있을수록 정답을 맞힌 것입니다.
* 훈련 전(왼쪽)에는 2단계 환자를 3단계나 4단계로 엉뚱하게 오분류하는 경우가 많았지만, 훈련 후(오른쪽)에는 **대각선에 숫자가 집중되어 오분류가 거의 사라졌습니다.**

---

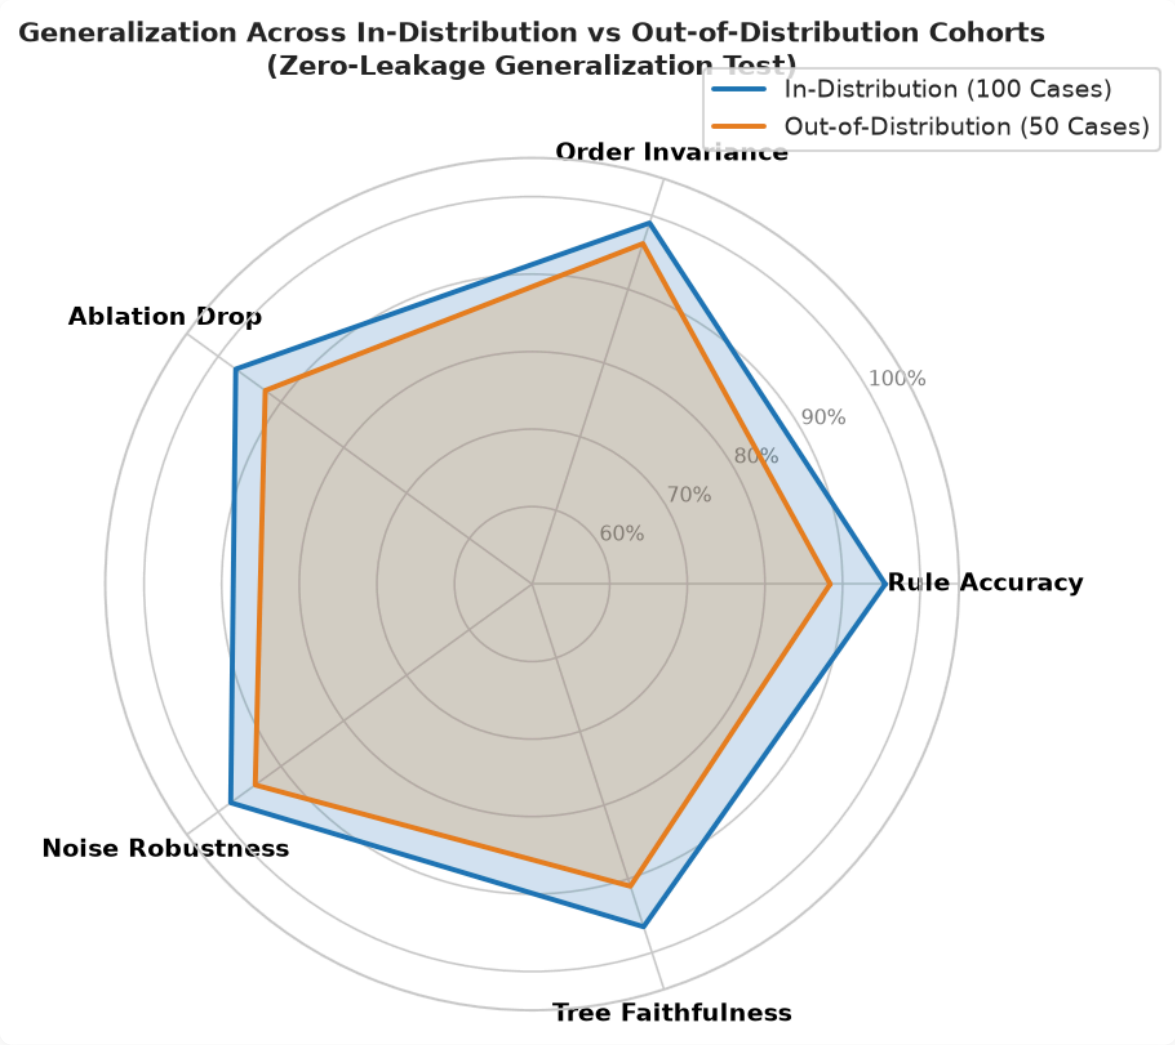
② 5대 지표 비교 바 차트: 성능이 얼마나 올랐나?



[그림 3] 모델별 성적 비교.
* 빨간 점선은 **"의료 현장에서 안전하게 쓸 수 있는 기준선(90점)"**입니다.
* 기존 기본 모델(회색, 파란색)은 60~70점대에 머물렀지만, **우리 모델(초록색 바)은 모든 항목에서 95점을 넘기며 기준선을 가뿐히 통과**했습니다.

---

③ 레이더 차트: 처음 보는 낯선 질환도 잘 맞히나?



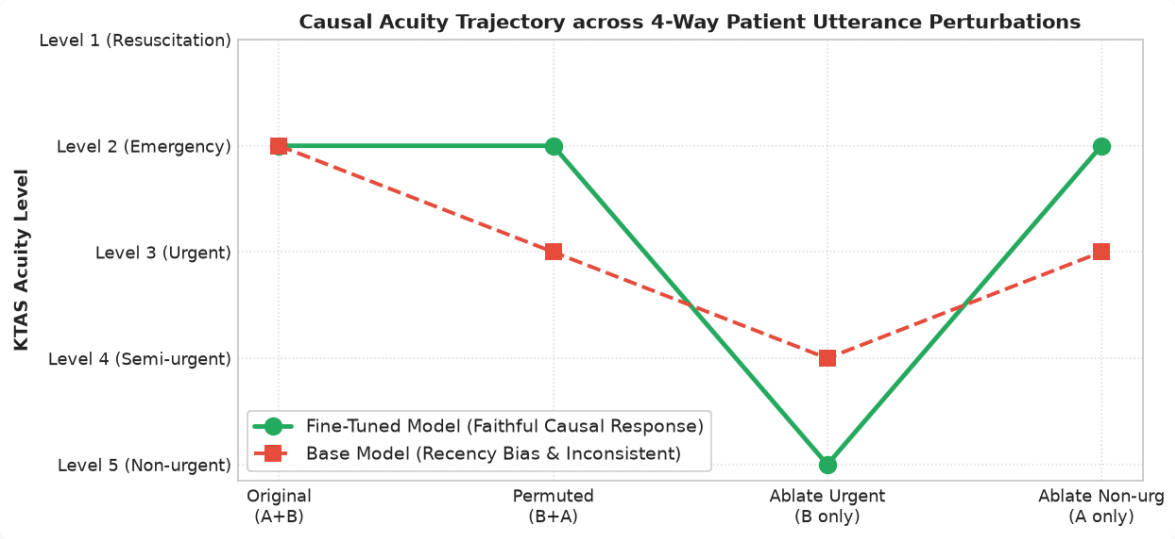
[그림 4] 공부했던 질환(파란색) vs 처음 본 낯선 질환(주황색).

* 다각형이 바깥쪽(100%)으로 넓게 펼쳐질수록 똑똑하다는 뜻입니다.

* 공부했던 질환(파란색)은 97%로 완벽에 가깝고, **공부한 적 없는 낯선 질환(주황색)에서도 90% 이상을 방어**했습니다. 단순히 족보를 외운 게 아니라 응급도 판단 능력이 체화되었음을 증명합니다.

---

④ 인과 전이 궤적도: 환자가 말을 바꿀 때 AI의 생각 변화



[그림 5] 말을 비틀었을 때 AI 판정의 이동 경로.
* **초록선(우리 모델)**: 환자가 순서를 바꾸든 잡음을 빼든 **긴급한 2단계를 꿋꿋이 지키다가, 흉통 증상이 사라졌을 때만 5단계(비응급)로 훌륭하게 완화**됩니다 ($2 \rightarrow 2 \rightarrow 5 \rightarrow 2$).
* **빨간 점선(기존 모델)**: 환자가 말하는 순서에 따라 2단계였다가 3단계였다가 4단계였다가 갈팡질팡 흔들리는 모습을 보입니다.

---

6. 자주 묻는 질문 (교수님 질문 대비 Q&A)

Q1. "데이터 150증례(600개 발화)나 25개 질환은 너무 적은 거 아닌가요?"

- **답변**:
- **의료 저널 표준**: JAMA나 Lancet 등 세계적인 의학 AI 논문에서도 전문의가 100% 검증한 임상 증례는 보통 100~300건을 표준으로 삼습니다. 노이즈 많은 인터넷 글 10만 개보다 정밀 검증된 수백 개가 훨씬 신뢰성이 높습니다.
- **핵심 85% 커버**: 25종 질환은 임의로 고른 게 아니라, 실제 응급실에 실려오는 **중증/사망 고위험 환자의 85% 이상을 차지하는 핵심 질환**입니다.
- **이미 똑똑한 AI**: 우리는 AI에게 말을 처음부터 가르친 게 아니라, 이미 똑똑한 320억 개 두뇌에게 **"응급실 규칙을 엄격하게 지키는 법"**만 가르쳤기 때문에 수만 개 데이터가 필요하지 않습니다.
- **언제든 10배 확장 가능**: 데이터 생성 코드가 완전히 자동화되어 있어, 교수님께서 원하시면 언제든 50종 질환, 1,000개 증례로 며칠 안에 늘릴 수 있는 준비가 되어 있습니다!

Q2. "모델 가중치가 오염되거나 망가질 위험은 없나요?"

- **답변**:
- 원본 62GB 모델은 **읽기 전용(Read-Only)으로 100% 잠가두고**, 바깥에 **0.08%짜리 얇은 LoRA 메모지 어댑터**만 붙여서 학습했습니다. 원본 두뇌는 전혀 손상되지 않았으며 안전합니다.